

Taller 6: Introducción al Aprendizaje Automático

Aproximación de Funciones mediante Redes de Base Radial (RBF)

Cálculo Científico — Licenciatura en Computación y Física
Facultad de Ciencias, Universidad Central de Venezuela

Julio de 2026

1. Introducción

En el aprendizaje supervisado, el objetivo es encontrar una función $s(\mathbf{x})$ que aproxime una etiqueta o valor y a partir de un conjunto de datos de entrenamiento $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$. Las **Funciones de Base Radial (RBF)** proponen que la respuesta del modelo es una combinación lineal de funciones locales (kernels) centradas en los datos conocidos.

A diferencia de la interpolación global (como la polinomial), las RBF son excelentes para manejar datos dispersos en dimensiones altas, lo que las convierte en precursoras de las redes neuronales modernas.

2. Fundamento Matemático

La función aproximante se define como una suma ponderada de núcleos gaussianos:

$$s(\mathbf{x}) = \sum_{j=1}^n w_j \phi(\|\mathbf{x} - \mathbf{x}_j\|)$$

donde $\|\mathbf{x} - \mathbf{x}_j\|$ es la distancia euclídea entre el punto de consulta $\mathbf{x}$ y el centro j . El núcleo (kernel) gaussiano viene dado por:

$$\phi(r) = \exp(-(\epsilon r)^2)$$

El parámetro ϵ (parámetro de forma) es crítico:

- Un ϵ pequeño genera funciones anchas (muchas influencia de vecinos lejanos).
- Un ϵ grande genera funciones estrechas (influencia solo muy local).

3. Entrenamiento y Regularización de Tikhonov

Para hallar los pesos $\mathbf{w}$, debemos resolver el sistema $\Phi \mathbf{w} = \mathbf{y}$. Sin embargo, si los datos tienen ruido o están muy cerca entre sí, la matriz Φ puede estar mal condicionada. Para estabilizar la solución, añadimos un término de **regularización** λ :

$$(\Phi + \lambda I) \mathbf{w} = \mathbf{y}$$

donde λ es un valor pequeño (por ejemplo, 10^{-6}) que penaliza pesos excesivamente grandes y suaviza la superficie resultante.

4. Tareas del Taller

1. **Generación de Datos:** Cree un conjunto de 100 puntos aleatorios en el plano $[-2, 2] \times [-2, 2]$. Genere sus valores y usando una función no lineal (ej. $\sin(x) \cos(y)$) y añada un ruido gaussiano pequeño.
2. **Implementación del Modelo:** Escriba una función en Python o R que construya la matriz Φ y resuelva el sistema regularizado para obtener w .
3. **Visualización de la Superficie:** Evalúe el modelo en una malla fina (50×50) y grafique la superficie de predicción.
4. **Estudio del Parámetro de Forma:** Presente tres gráficas variando ϵ (pequeño, óptimo y grande). Explique el fenómeno de oscilación numérica cuando $\epsilon \rightarrow 0$.

5. Entregables

Informe técnico con la derivación del sistema lineal, el código fuente comentado y una discusión sobre cómo la regularización λ ayuda a ignorar el ruido en los datos de entrenamiento.