

UNIVERSIDAD CENTRAL DE VENEZUELA
FACULTAD DE CIENCIAS
LICENCIATURA EN COMPUTACIÓN
CÁLCULO CIENTÍFICO

Taller 6: Introducción al Aprendizaje Automático

*Aproximación de Funciones mediante Redes de Base
Radial (RBF)*

Semestre 2026-I

Integrantes:

Carlos Paccagnella. C.I.: 31.752.534

Diego León. C.I.: 31.549.189

Fecha: 9 de octubre de 2026

1. Introducción

En el ámbito del aprendizaje automático supervisado, uno de los problemas fundamentales es la regresión y aproximación de funciones. El objetivo central consiste en encontrar una función continua $s(x)$ que logre aproximar de manera óptima una etiqueta o valor objetivo y , a partir de un conjunto finito de datos de entrenamiento dispersos definidos como $\{(x_i, y_i)\}_{i=1}^n$. Para resolver este problema en dominios de alta dimensionalidad, la aproximación mediante Funciones de Base Radial (RBF, por sus siglas en inglés) se presenta como una de las arquitecturas matemáticas más robustas.

A diferencia de las técnicas de interpolación global tradicionales (como la interpolación polinomial de Lagrange o diferencias divididas), las cuales sufren de inestabilidades severas al aumentar el número de nodos, el modelo RBF propone que la respuesta global del sistema esté conformada por una combinación lineal armónica de múltiples funciones locales (denominadas núcleos). Estas funciones locales se centran de manera individual en cada uno de los datos conocidos, permitiendo que la superficie de predicción se adapte elásticamente a la topología de la información.

Este informe técnico documenta exhaustivamente la derivación matemática, la implementación computacional y el análisis cuantitativo de un modelo RBF diseñado para aproximar una superficie no lineal perturbada deliberadamente con ruido gaussiano. El estudio se enfocará especialmente en el análisis del condicionamiento matricial, el impacto crítico del parámetro de forma geométrica y la necesidad imperativa de aplicar la regularización de Tikhonov para garantizar la estabilidad numérica del sistema predictivo.

2. Fundamento Matemático y Derivación del Sistema

2.1. Definición de la Función Aproximante y el Núcleo Gaussiano

La función aproximante subyacente en el modelo de Redes de Base Radial se define algebraicamente como una suma ponderada de funciones simétricas respecto a un centro. La formulación general es:

$$s(x) = \sum_{j=1}^n w_j \phi(\|x - x_j\|) \quad (1)$$

Donde la norma $\|x - x_j\|$ representa la distancia euclídea estricta entre un punto de consulta arbitrario x (en el dominio de evaluación) y el centro de entrenamiento específico j . Los coeficientes w_j son los pesos estadísticos que determinan la contribución (amplitud) de cada función local a la predicción final.

Para este estudio, el núcleo elegido es la campana gaussiana, cuya expresión analítica viene dada por:

$$\phi(r) = \exp(-(\epsilon r)^2) \quad (2)$$

En esta formulación, la variable r sustituye a la distancia euclídea, y el parámetro ϵ actúa como el parámetro de forma geométrica. El rol de ϵ es absolutamente crítico para la topología de la red:

- Un valor de ϵ **pequeño** genera funciones gaussianas extremadamente anchas (aplanadas). Esto implica que la evaluación en un punto x recibirá una enorme influencia no solo de sus vecinos más próximos, sino también de centros de entrenamiento lejanos, lo que tiende a difuminar las características locales de la función.
- Un valor de ϵ **grande** genera funciones gaussianas muy estrechas (agudas o afiladas). En este escenario, la influencia de cada núcleo decae drásticamente a medida que nos alejamos de su centro, provocando que la red actúe de manera hiperlocalizada, asemejándose a un método de interpolación de vecino más cercano.

2.2. El Sistema Lineal y el Problema del Mal Condicionamiento

Para hallar el vector óptimo de pesos $w = [w_1, w_2, \dots, w_n]^T$, se impone inicialmente una condición de interpolación estricta. Esto significa que exigimos que la función $s(x)$ pase exactamente por los valores objetivo y en todos los nodos de entrenamiento. Al evaluar la Ecuación (1) en los n centros, se obtiene un sistema de ecuaciones lineales cuadrado de la forma:

$$\Phi w = y \quad (3)$$

Donde $\Phi \in \mathbb{R}^{n \times n}$ es la matriz de diseño (o matriz de interpolación), cuyas entradas están dadas por $\Phi_{ij} = \phi(\|x_i - x_j\|)$.

Desde el punto de vista del análisis numérico, la resolución directa de este sistema presenta severos desafíos. Un problema algebraico se considera mal condicionado si pequeños cambios en los datos de entrada pueden producir cambios desproporcionadamente grandes en los resultados o respuestas computadas. Dado que nuestro vector de datos y ha sido contaminado con ruido gaussiano, existe una incertidumbre inherente en el sistema. Debido a su gran sensibilidad incluso carece de sentido matemático intentar resolver sistemas mal condicionados en presencia de incertidumbre en los datos.

Si la matriz Φ posee un número de condición $\kappa(\Phi)$ muy elevado, una perturbación minúscula en el vector de observaciones y (como el ruido de medición) no garantiza que la perturbación resultante en el vector de pesos calculados w sea pequeña; por el

contrario, el sistema se vuelve inestable y los pesos adquieren magnitudes colosales para intentar compensar el error. Además, se puede demostrar que las columnas de una matriz que sufre de mal condicionamiento son “casi” linealmente dependientes, lo que acerca peligrosamente a la matriz a la singularidad.

2.3. Regularización de Tikhonov

Para mitigar la inestabilidad inherente de la matriz de diseño y estabilizar el problema inverso, se abandona la exigencia de la interpolación exacta y se modifica la formulación mediante la Regularización de Tikhonov (también conocida como *Ridge Regression*). El sistema lineal regularizado se define como:

$$(\Phi + \lambda I)w = y \quad (4)$$

Donde I es la matriz identidad de dimensiones $n \times n$, y $\lambda > 0$ es un hiperparámetro escalar de penalización (comúnmente muy pequeño, del orden de 10^{-6}).

Físicamente, la suma del término λI refuerza la diagonal principal de la matriz de diseño, alejando sus autovalores del cero y reduciendo drásticamente el número de condición κ . Conceptualmente, esto transforma el problema en una minimización que busca un equilibrio: se minimiza el error de aproximación frente a los datos y , pero al mismo tiempo se penaliza la norma euclidiana del vector de pesos w , impidiendo que estos crezcan descontroladamente. El resultado directo es una superficie predictiva mucho más suave y robusta frente a perturbaciones.

3. Implementación Computacional y Metodología

El modelado experimental se programó en su totalidad utilizando el lenguaje Python, apoyándose en las librerías de cálculo científico `numpy` y `scipy` para garantizar el manejo vectorizado y eficiente de las matrices.

1. Generación del Espacio de Datos: Se simuló un escenario de muestreo generando $n = 100$ puntos espaciales distribuidos de forma completamente aleatoria bajo una distribución uniforme bidimensional. El dominio acotado de trabajo se estableció en el plano $[-2, 2] \times [-2, 2]$.

2. Función Subyacente y Ruido Estadístico: Para cada par de coordenadas (x_i, y_i) generado, se calculó su verdadera elevación topológica utilizando la función trigonométrica no lineal $z_{verdadero} = \sin(x) \cos(y)$. Con el fin de evaluar la resiliencia del modelo RBF, se inyectó una perturbación estocástica a las observaciones. Se sumó un ruido blanco gaussiano definido por una media $\mu = 0,0$ y una desviación estándar pequeña de $\sigma = 0,1$. Este vector $z_{ruidoso}$ se convirtió en el objetivo y para el entrenamiento de la red.

3. Construcción del Sistema y Predicción: Haciendo uso de la función `cdist` (optimización espacial de `scipy`), se calcularon las matrices de distancias

euclídeas cruzadas para ensamblar la matriz simétrica Φ . El vector de coeficientes w fue hallado mediante la resolución directa del sistema regularizado empleando el factor $\lambda = 10^{-6}$. Finalmente, para visualizar el comportamiento continuo de la red neuronal ya entrenada, se proyectó el modelo RBF evaluando la función aproximante $s(x)$ sobre una malla cuadriculada y muy densa de 50×50 puntos, barriendo de manera determinista todo el dominio espacial original.

4. Análisis Cuantitativo y Discusión Teórica

4.1. El Impacto del Parámetro de Forma y la Oscilación Numérica

La fidelidad geométrica de la superficie predicha depende visceralmente de la calibración del parámetro de forma ϵ . Se ejecutaron tres experimentos variando su magnitud para estudiar el comportamiento analítico del modelo:

- **El escenario sub-ajustado (ϵ Grande, $\epsilon = 10,0$):** Bajo este régimen, el decaimiento de las funciones exponenciales gaussianas es extremadamente violento. La red RBF se vuelve incapaz de generalizar en los espacios vacíos entre los datos. La superficie tridimensional resultante exhibe una topología plana global (con un valor cercano a cero) interrumpida por picos muy agudos (agujas) aislados exclusivamente en las coordenadas exactas de los centros de entrenamiento. El modelo pierde toda noción de continuidad estructural.
- **El escenario óptimo ($\epsilon = 1,0$):** Al utilizar un parámetro equilibrado, el ancho de banda del núcleo gaussiano permite una superposición armónica entre las funciones de base locales. La predicción RBF resultante es fluida, continua y logra perfilar magistralmente los valles y crestas característicos de la función original $\sin(x) \cos(y)$.
- **La catástrofe de la Oscilación (ϵ Pequeño, $\epsilon \rightarrow 0$):** El análisis teórico exige evaluar el límite cuando el parámetro de forma tiende a cero. Analíticamente, si $\epsilon \rightarrow 0$, entonces el término $\exp(-(er)^2)$ tiende irremediablemente a 1 sin importar cuán grande sea la distancia r . Físicamente, las funciones de base se vuelven infinitamente anchas y planas. En el álgebra matricial de la matriz Φ , esto provoca que todos sus elementos tiendan a uno, forzando a que las filas y columnas se vuelvan coplanares y casi linealmente dependientes. Al colapsar el determinante, el sistema se vuelve patológicamente mal condicionado. Al intentar compensar este colapso, el algoritmo asigna pesos w_j con magnitudes colosales (astronómicas) y signos matemáticamente opuestos de forma alterna. La suma de estos enormes núcleos contrapuestos genera severos errores de cancelación en la aritmética de punto flotante. Esto produce oscilaciones salvajes y violentas en la superficie resultante, un comportamiento destructivo

que es conceptualmente análogo al temido fenómeno de oscilación observado al emplear polinomios de grado alto para interpolación en nodos equiespaciados.

4.2. El Rol Vital de la Regularización para Ignorar el Ruido

La comprensión de por qué la regularización λ ayuda a ignorar el ruido radica en la flexibilización de los requerimientos matriciales. Si omitiéramos la matriz de identidad penalizadora ($\lambda = 0$), el sistema mal condicionado obligaría a la función RBF de múltiples dimensiones a deformarse radicalmente, creando irregularidades forzadas para lograr atravesar exactamente cada dato empírico, incluyendo los errores estocásticos (ruido gaussiano) añadidos artificialmente en la Fase 1 de este estudio. Este fenómeno se conoce estadísticamente como sobreajuste (*overfitting*).

Al introducir $\lambda = 10^{-6}$, sacrificamos una minúscula fracción de la precisión absoluta en los nodos de control a cambio de una inmensa ganancia en la suavidad global. La regularización actúa de facto como un filtro de paso bajo: asfixia las oscilaciones de alta frecuencia (el ruido) penalizando cualquier intento del vector de pesos w por alcanzar valores desproporcionados, permitiendo que la red RBF revele con extraordinaria limpieza la geometría verdadera de la superficie subyacente de interés.

4.3. Inspección Numérica del Sistema y Cancelación Extrema

La ejecución del algoritmo arrojó evidencia fundamental sobre la topología del sistema lineal. Al inspeccionar la matriz de diseño Φ generada para $\epsilon = 1,0$, se comprobó empíricamente que su diagonal principal está poblada por unos (dado que $\phi(0) = \exp(0) = 1$), mientras que los valores extradiagonales decaen de forma abrupta (del orden de 10^{-2} y 10^{-5}), reflejando la naturaleza localizadora del núcleo gaussiano.

Por otro lado se observó algo llamativo. Una muestra de los primeros coeficientes calculados arrojó magnitudes colosales con signos estrictamente alternantes:

$w = [1018.35, \quad 16075.46, \quad 4013.01, \quad -26665.48, \quad 2687.28, \quad \dots]$

Este fenómeno corrobora la severidad del mal condicionamiento matricial discutido teóricamente. Para lograr ajustar la superficie a los datos ruidosos, el modelo RBF se ve forzado a asignar amplitudes titánicas a los núcleos locales. La superficie suave que observamos en las gráficas no es más que el residuo de una **cancelación numérica masiva** entre estas inmensas funciones positivas y negativas superpuestas. Esto demuestra de manera irrefutable que, de no haber incluido el hiperparámetro de regularización de Tikhonov ($\lambda = 10^{-6}$), la matriz habría sido numéricamente singular y los pesos habrían divergido hacia el infinito, destruyendo la aproximación por completo.

4.4. Análisis Visual de las Superficies Predictivas

La renderización tridimensional del experimento (ver anexos gráficos) confirma el comportamiento topológico esperado:




Figura 1: Datos Sintéticos Generados.

- **Resiliencia al Ruido:** En la gráfica de la aproximación óptima ($\epsilon = 1,0$, $\lambda = 10^{-6}$), se observa claramente cómo la superficie elástica generada atraviesa la nube de datos mitigando las variaciones estocásticas.




Figura 2: Aproximación RBF óptima.

Los puntos rojos (datos con ruido) no yacen exactamente sobre la membrana, demostrando que el modelo ha evitado el sobreajuste y ha extraído exitosamente el patrón de baja frecuencia correspondiente a $\sin(x) \cos(y)$.

- **Degradación por Parámetro de Forma:** El panel comparativo de ϵ resulta revelador.




Figura 3: Estudio comparativo del parámetro de forma.

Para un ϵ pequeño (0,1), la extrema anchura de los núcleos difumina las crestas y valles trigonométricos, aplanando la superficie. Por el contrario, un ϵ grande (10,0) anula la superposición entre núcleos vecinos; el modelo fracasa en ge-

neralizar y la superficie colapsa a un plano nulo perforado por agujas aisladas que intentan interpolar los datos de manera hiperlocalizada.

5. Conclusiones

El desarrollo de este experimento valida categóricamente la potencia matemática y predictiva de las Redes de Base Radial (RBF) como esquemas de aproximación multivariable. A diferencia de los métodos de interpolación clásicos, las RBF demuestran una capacidad superior para lidiar con conjuntos de datos dispersos (nubes de puntos) en dimensiones múltiples sin requerir una estructuración previa de mallas.

Sin embargo, se ha demostrado matemática y empíricamente que la arquitectura RBF carece de viabilidad operativa a menos que se optimicen dos factores críticos simultáneamente. En primer lugar, el parámetro de forma geométrica (ϵ) debe calibrarse para evitar el colapso hacia la dependencia lineal de las columnas matriciales y las consecuentes oscilaciones numéricas destructivas. En segundo lugar, y más importante aún, ante la presencia inevitable de ruido y el mal condicionamiento inherente de las matrices de interpolación simétricas, la incorporación de la estabilización de Tikhonov (λ) deja de ser opcional y se convierte en una herramienta insustituible para evitar el sobreajuste y preservar la integridad topológica del modelo predictivo general.